

# Sprawozdanie z projektu

## Szeregi czasowe

Kamil Baran 166631  
Inżynieria i analiza danych

## Spis treści

1. Użyte dane.....	3
2. Wczytanie danych do środowiska R-studio.....	3
2.1 Widok danych w R-studio.....	3
3. Stworzenie szeregów czasowych .....	4
4. Omówienie głównych cech analizowanych szeregów.....	5
5. Dekompozycja .....	11
5.1 Dekompozycja model regresji .....	13
6. Usuwanie trendu i sezonowości.....	14
7. Stworzenie szeregów stacjonarnych .....	15
7.2 Sprawdzanie czy szereg jest realizacją szumu białego .....	17
8. Wyznaczanie rzędów dla modeli AF, oraz MA.....	18
9. Wyznaczenie współczynnika modelu AR.....	21
10. Współczynnik modelu MA.....	23
11. Wyznaczanie optymalnych modeli z użyciem auto.arima() .....	24
12. Prognozowanie z wykorzystaniem metod naiwnych .....	26
12.1 Wybór najlepszej metody.....	31

## 1. Użyte dane

W swoim projekcie użyłem 2 rodzajów danych pobranych ze strony <https://fred.stlouisfed.org/>.

Pierwszy rodzaj miał posiadać wyraźny trend a drugi wyraźną sezonowość.

Tematy, które wybrałem:

- Średnie tygodniowe zarobki pracowników produkcyjnych i nie nadzorczych

Dane te reprezentują średnie zarobki pracowników w latach od 1939 do 2022 roku. Podczas tworzenia szeregu ograniczyłem dane do roku 1968.

- Nowe prywatne jednostki mieszkalne autoryzowane przez pozwolenie na budowę dla Kalifornii

Dane te pokazują ilość jednostek mieszkalnych od 1998 roku do 2022r. w Kalifornii

## 2. Wczytanie danych do środowiska R-studio

```
4  
5 #wczytanie danych  
6 zarobki <- read.csv("C:/Users/Kamil/Desktop/projekt szeregi/zarobki.csv")  
7  
8 colnames(zarobki) <- c("Data", "Ilosc_dolarow_na_tydzien")  
9  
10 domy <- read.csv("C:/Users/Kamil/Desktop/projekt szeregi/domy.csv")  
11  
12 colnames(domy) <- c("Data", "Ilosc_domow")  
13
```

### 2.1 Widok danych w R-studio

	Data	Ilosc_dolarow_na_tydzien
1	1968-01-01	113.52
2	1968-02-01	115.06
3	1968-03-01	115.87
4	1968-04-01	114.86
5	1968-05-01	117.38
6	1968-06-01	117.79
7	1968-07-01	117.91
8	1968-08-01	117.62
9	1968-09-01	119.43
10	1968-10-01	120.54

	Data	Ilość domów
1	1988-01-01	16466.483
2	1988-02-01	19704.379
3	1988-03-01	19420.946
4	1988-04-01	21148.678
5	1988-05-01	19129.808
6	1988-06-01	21077.471
7	1988-07-01	18940.715
8	1988-08-01	22646.439
9	1988-09-01	20723.744
10	1988-10-01	22482.934

### 3. Stworzenie szeregów czasowych


```

15
16 #wybieramy 2 kolumny z każdej z wczytanych danych
17 zarobki2 <- zarobki[,2]
18 domy2 <- domy[,2]
19 |
20 #stworzenie szeregów czasowych
21 (domys <- ts(domy2, start = c(1988,1), frequency = 12))
22 (zarobkis <- ts(zarobki2, start = c(1968,1), frequency = 12))
23
24

```


#### 4. Omówienie głównych cech analizowanych szeregów

- Dane I – jednostki mieszkalne




Rysunek 1 Monthplot - Dane 1

- Dane II- średnie zarobki



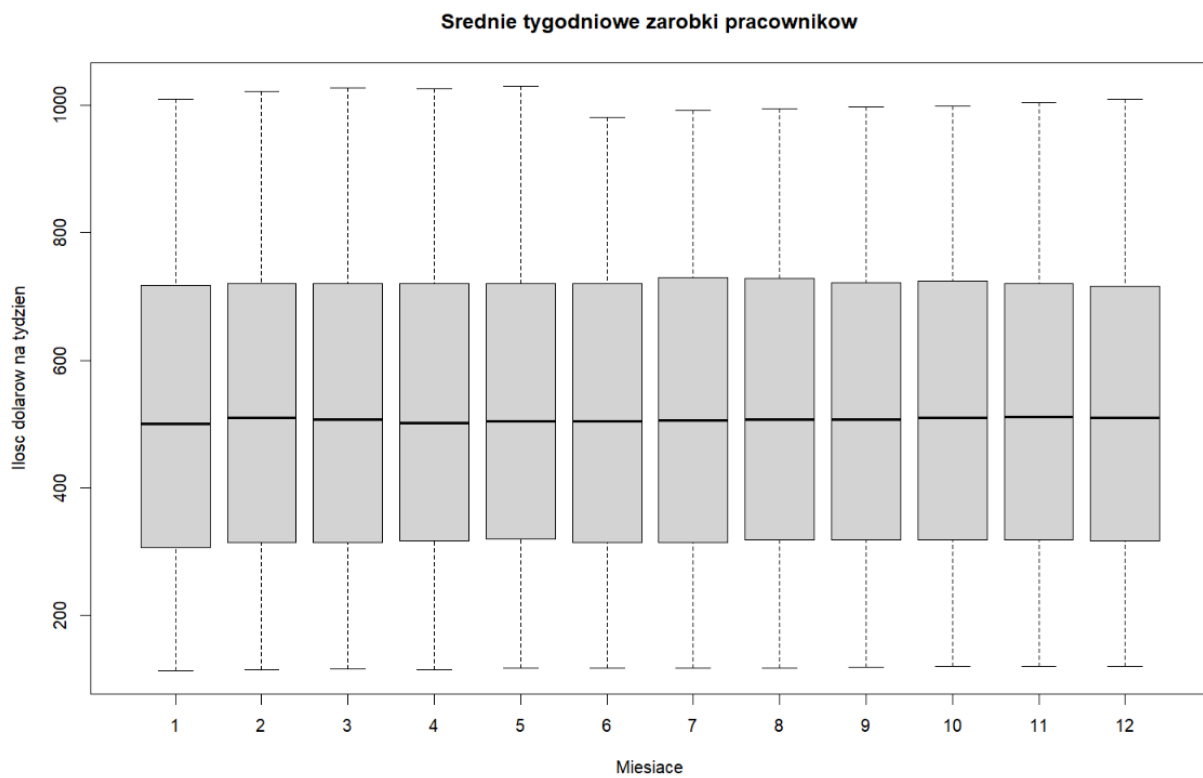
Rysunek 2- Monthplot - dane 2

- Dane I




Rysunek 3- Boxplot- dane 1

- Dane II



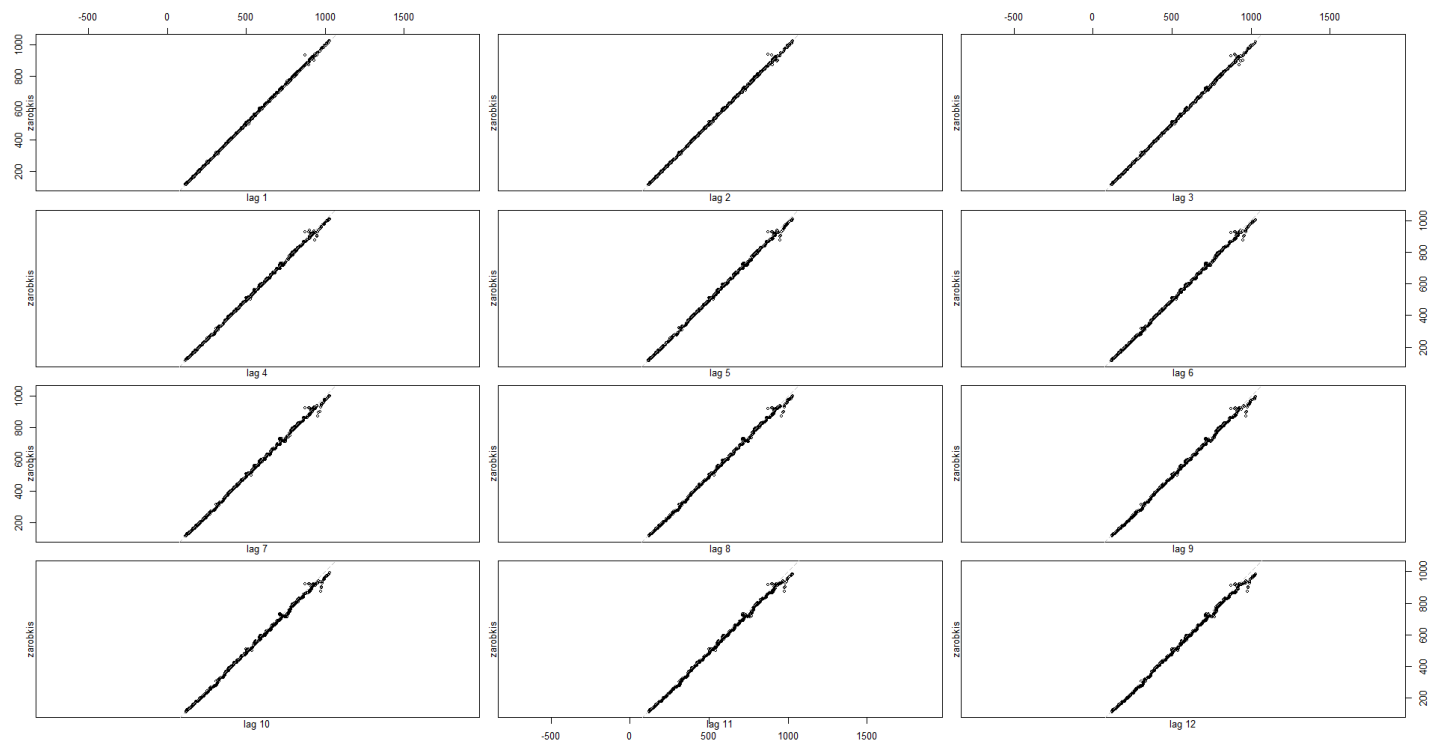
*Rysunek 4- Boxplot dane2*

- Dane I



*Rysunek 5 Lag plot-dane I*


- Dane II



Rysunek 6 Lag plot - dane 2


- Dane I

## Series domys

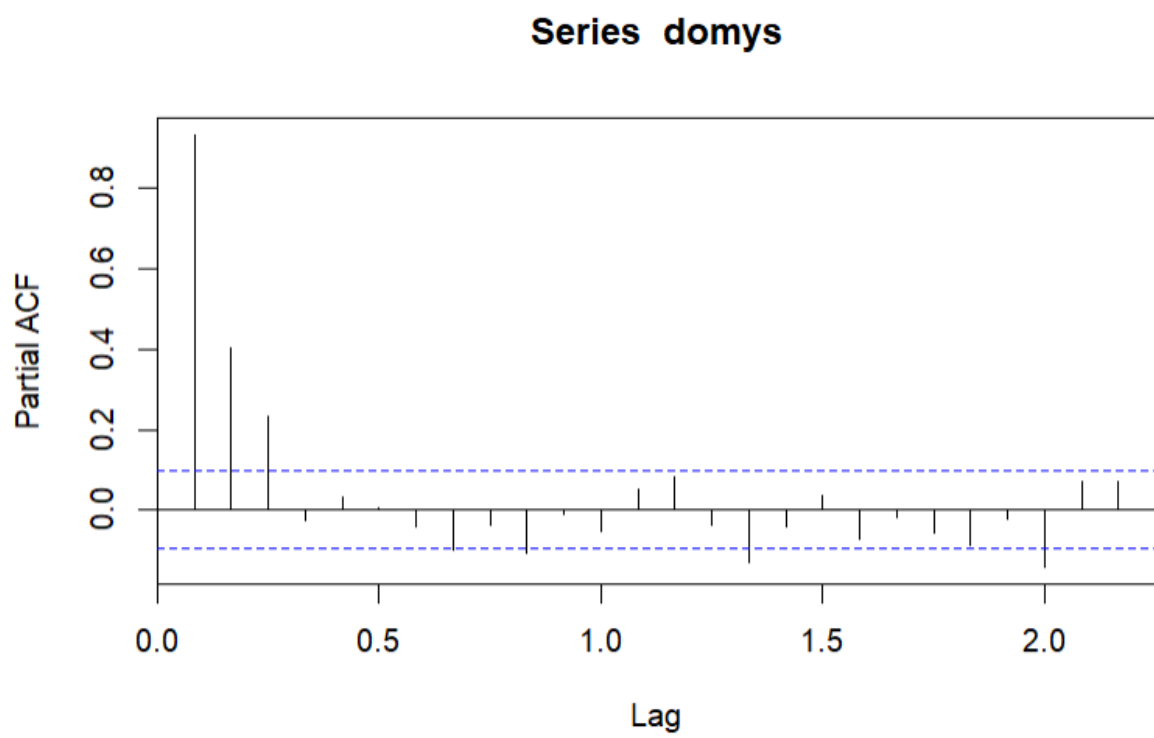




- Dane II
- 




- Dane I




- Dane II

### Series zarobkis



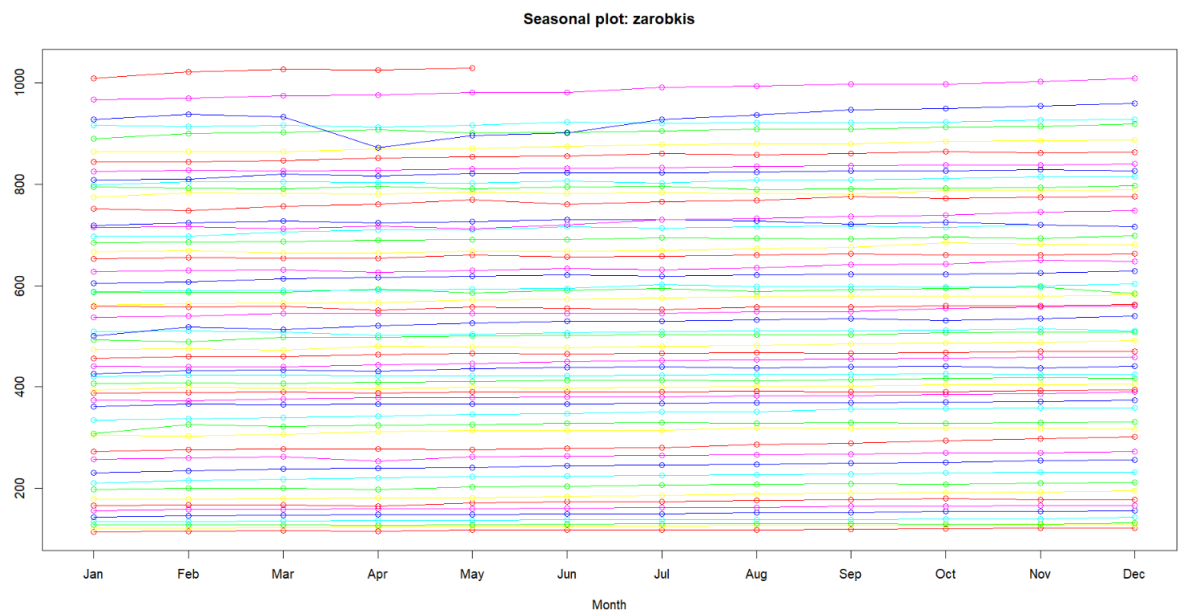
- Dane I

Seasonal plot: domys



Rysunek 7 seasonal plot

- Dane II



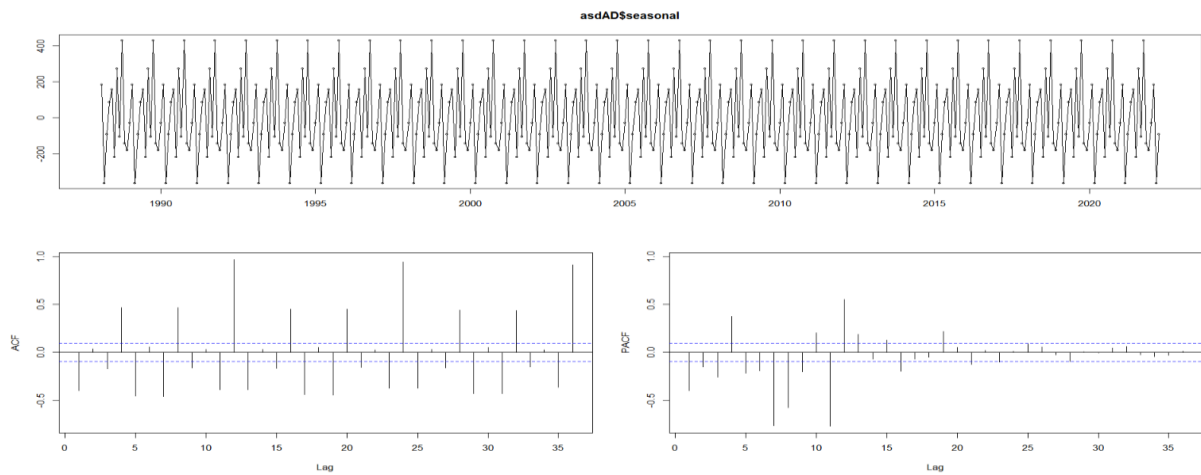

Rysunek 8 seasonal plot dane2

## 5. Dekompozycja

Zrobiłem dekompozycję multiplikatywną, oraz addytywną. Wyznaczyłem również trendy z uwzględnieniem sezonowości.

- Dane I

```
45 #dekompozycja----
46 #I dane
47 adddomy <- decompose(domys, type = "additive")
48 plot(adddomy)
49 asdd<-diff(domys, lag.max = 1)
50 asdAD <- decompose(asdd, type="additive")
51 plot(asdAD)
52 plot(asdd)
53 tsdisplay(asdAD$seasonal)
54
```




- Dane II

```

55  #II dane
56  zarobkim <- decompose(zarobkis, type = "multiplicative")
57  plot(zarobkim)
58  adzarobki <- decompose(zarobkis, type = "additive")
59  plot(adzarobki)
60

```


## Decomposition of multiplicative time series



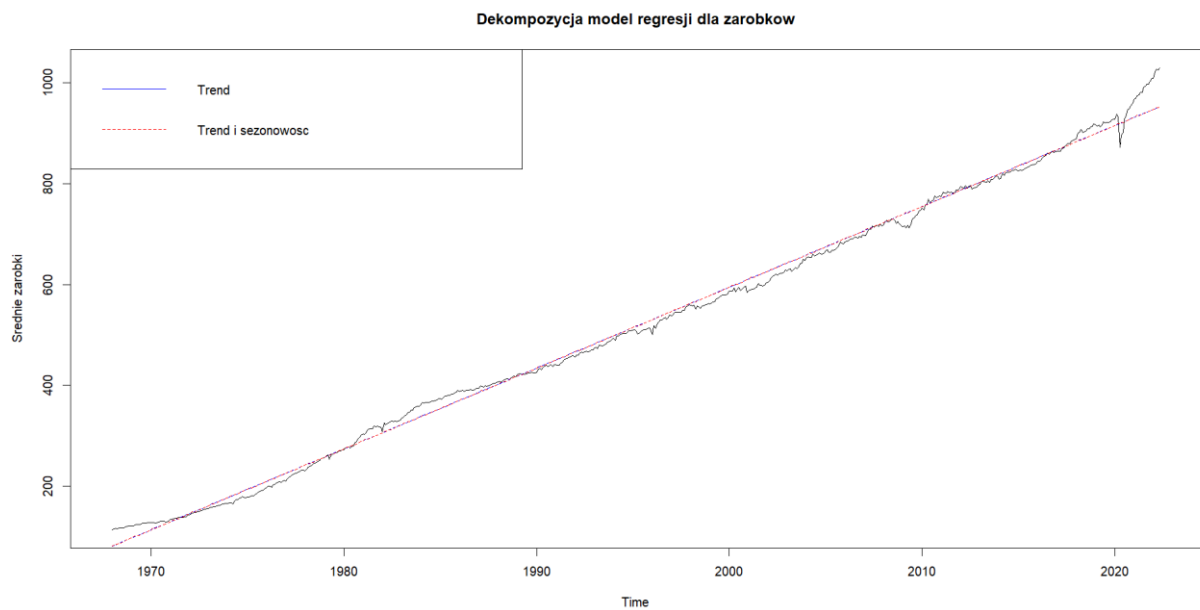
### 5.1 Dekompozycja model regresji

Wyznaczyłem trendy liniowe z uwzględnieniem sezonowości

- Dane I




- Dane II



## 6. Usuwanie trendu i sezonowości

- Dane I




```

82 domy_sez <- diff(domys, lag = 12)
83 tsdisplay(domy_sez)
84 domy_sez_trend <- diff(domy_sez, lag = 1)
85 tsdisplay(domy_sez_trend, main = "Trend")
86

```

- Dane II



## 7. Stworzenie szeregów stacjonarnych

Przed pozbyciem się sezonowości musiałem wcześniej pozbyć się trendu. Zrobiłem to powyżej. Teraz tworzę szereg stacjonarny, a następnie sprawdzam czy szereg jest realizacją szumu białego.

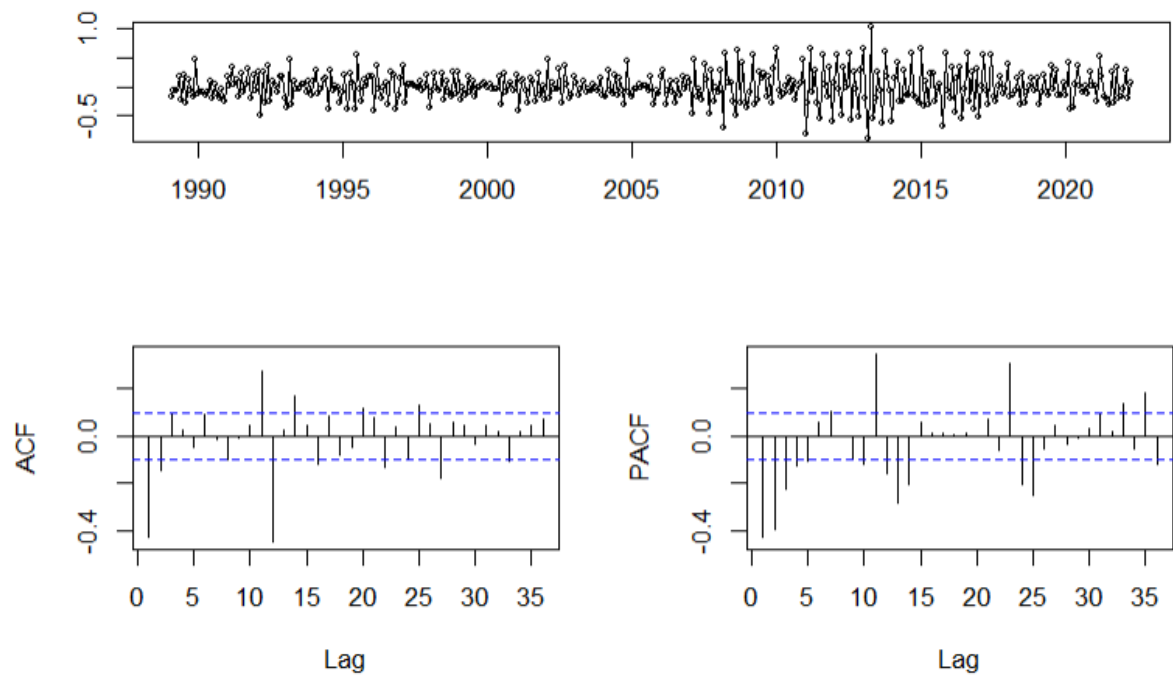
- Dane I

```

95 tsdisplay(domys)
96 domyst <- BoxCox(domys, lambda = 0)
97 tsdisplay(domyst)
98 domyst2 <- diff(domyst, lag = 12)
99 tsdisplay(domyst2)
100 domyst3 <- diff(domyst2, lag = 1)
101 tsdisplay(domyst3)
102


```

### domyst3



- Dane II

### zarobst3





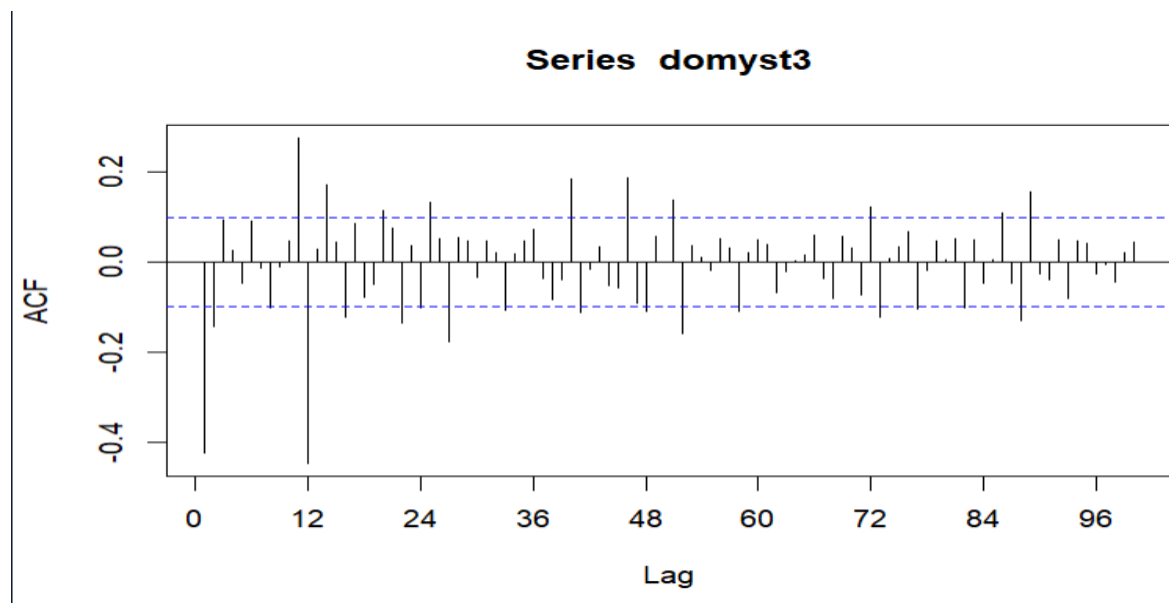
```

103 #IIdane
104 tsdisplay(zarobkis)
105 zarobst <- BoxCox(zarobkis, lambda = 0)
106 tsdisplay(zarobst)
107 zarobst2 <- diff(zarobst, lag = 12)
108 tsdisplay(zarobst2)
109 zarobst3 <- diff(zarobst2, lag = 1)
110 tsdisplay(zarobst3)
111

```

## 7.2 Sprawdzanie czy szereg jest realizacją szumu białego


- Dane I



Wniosek:

Szereg ten nie jest realizacją szumu białego, ponieważ mniej niż 95% autokorelacji próbkowych mieści się w przedziale ufności, oraz występują wartości istotnie wychodzące poza ten przedział

- Dane II



Wniosek:

Szereg ten nie jest realizacją szumu białego, ponieważ występują wartości istotnie wychodzące poza ten przedział.

## 8. Wyznaczanie rzędów dla modeli AF, oraz MA

Kolejnym etapem jest wyznaczenie rzędów, będą nam one potrzebne do wyznaczenia modeli AR i MA

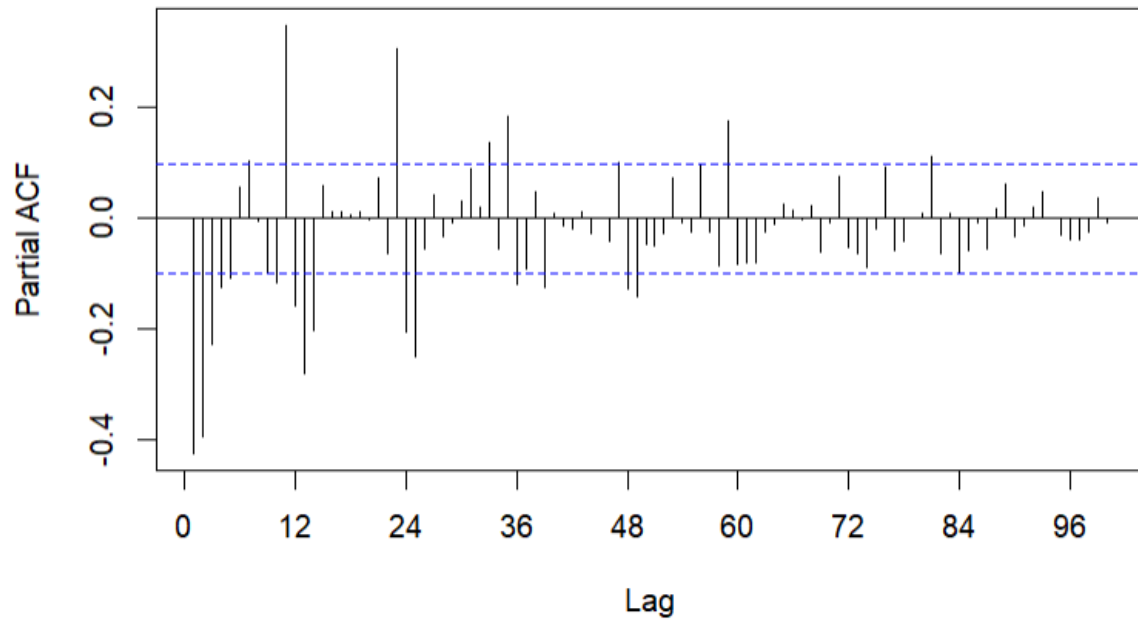
```

125 Acf(domyst3, lag.max = 100) #q=12
126 Pacf(domyst3, lag.max = 100) #p=62
127
128 #ar(zarobst3,aic = TRUE, order.max = 100)
129 Acf(zarobst3, lag.max = 100) #q=12
130 Pacf(zarobst3, lag.max = 100) #p=60
131


```

- Dane I


**Series domyst3**




**Series domyst3**



**Series zarobst3**



**Series zarobst3**



## 9. Wyznaczenie współczynnika modelu AR

- Dane I

```
134 #współczynnik modelu AR----
135 #Idane
136 (domyar <- ar(domyst3 , aic = FALSE, order.max = 62, method = "yule-walker"))
137 (domyar2 <- ar(domyst3, aic = FALSE, order.max = 62, method = "burg"))
138
139 (domyarauto <- ar(domyst3, aic = TRUE, order.max = 100))
```

```
Call:
ar(x = domyst3, aic = FALSE, order.max = 62, method = "yule-walker")
```

Coefficients:

1	2	3	4	5	6	7	8	9	10	11
-0.6587	-0.4264	-0.1779	-0.0918	0.0077	0.1780	0.1767	0.0366	0.0559	0.0490	0.1147
12	13	14	15	16	17	18	19	20	21	22
-0.7840	-0.5217	-0.1801	0.0239	-0.0122	0.0869	0.2102	0.2405	0.1499	0.1757	0.0409
23	24	25	26	27	28	29	30	31	32	33
0.0914	-0.6852	-0.4233	-0.1476	-0.0476	0.0248	0.1461	0.2179	0.2705	0.1720	0.1464
34	35	36	37	38	39	40	41	42	43	44
0.0122	0.0993	-0.4406	-0.2995	-0.1477	-0.1087	0.0214	0.0464	0.0504	0.0987	0.0377
45	46	47	48	49	50	51	52	53	54	55
-0.0366	-0.0493	0.0193	-0.3661	-0.2870	-0.1392	-0.0013	0.0215	0.0613	0.0399	0.0606
56	57	58	59	60	61	62				
0.0803	-0.0253	-0.0234	0.0739	-0.1672	-0.1314	-0.0783				

Order selected 62 sigma^2 estimated as 0.02505

```
Call:
ar(x = domyst3, aic = FALSE, order.max = 62, method = "burg")
```

Coefficients:

1	2	3	4	5	6	7	8	9	10	11
-0.6508	-0.4124	-0.1709	-0.0964	0.0082	0.1719	0.1836	0.0545	0.0880	0.0811	0.1741
12	13	14	15	16	17	18	19	20	21	22
-0.8281	-0.5448	-0.1985	0.0274	-0.0314	0.0761	0.2092	0.2568	0.1517	0.2076	0.0784
23	24	25	26	27	28	29	30	31	32	33
0.1777	-0.7576	-0.4859	-0.1913	-0.0670	-0.0193	0.1155	0.2214	0.3038	0.1680	0.1846
34	35	36	37	38	39	40	41	42	43	44
0.0771	0.2349	-0.4722	-0.3407	-0.1660	-0.1313	-0.0184	0.0113	0.0399	0.0969	0.0040
45	46	47	48	49	50	51	52	53	54	55
-0.0466	-0.0174	0.1056	-0.3945	-0.3385	-0.1435	-0.0272	0.0051	0.0527	0.0481	0.0717
56	57	58	59	60	61	62				
0.0817	-0.0242	0.0072	0.1427	-0.1517	-0.1504	-0.0620				

Order selected 62 sigma^2 estimated as 0.01833

```
Call:
ar(x = domyst3, aic = TRUE, order.max = 100)
```

Coefficients:

1	2	3	4	5	6	7	8	9	10	11
-0.6587	-0.4264	-0.1779	-0.0918	0.0077	0.1780	0.1767	0.0366	0.0559	0.0490	0.1147
12	13	14	15	16	17	18	19	20	21	22
-0.7840	-0.5217	-0.1801	0.0239	-0.0122	0.0869	0.2102	0.2405	0.1499	0.1757	0.0409
23	24	25	26	27	28	29	30	31	32	33
0.0914	-0.6852	-0.4233	-0.1476	-0.0476	0.0248	0.1461	0.2179	0.2705	0.1720	0.1464
34	35	36	37	38	39	40	41	42	43	44
0.0122	0.0993	-0.4406	-0.2995	-0.1477	-0.1087	0.0214	0.0464	0.0504	0.0987	0.0377
45	46	47	48	49	50	51	52	53	54	55
-0.0366	-0.0493	0.0193	-0.3661	-0.2870	-0.1392	-0.0013	0.0215	0.0613	0.0399	0.0606
56	57	58	59	60	61	62				
0.0803	-0.0253	-0.0234	0.0739	-0.1672	-0.1314	-0.0783				

Order selected 62 sigma^2 estimated as 0.02505

Z powyższych screenów możemy wnioskować, że wartość policzona metodą Yule-Walkera, oraz Burga dla  $p=62$  jest taka samo jak obliczona automatycznie.

- Dane II

```
140 #IIDane
141 (zarar <- ar(zarobst3, aic = FALSE, order.max = 60, method = "yule-walker"))
142 (zarar2 <- ar(zarobst3, aic = FALSE, order.max = 60, method = "burg"))
143
144 (zarar2auto <- ar(zarobst3, aic = TRUE, order.max = 100))
145
```

```
Call:
ar(x = zarobst3, aic = FALSE, order.max = 60, method = "yule-walker")

Coefficients:
 1      2      3      4      5      6      7      8      9     10     11
-0.2556 -0.0436 -0.0089  0.0264 -0.0710 -0.0070 -0.0348  0.0417  0.0479 -0.0099  0.0478
 12     13     14     15     16     17     18     19     20     21     22
-0.8540 -0.2100 -0.0259  0.0276  0.0154 -0.0756 -0.0481 -0.0435  0.0814  0.0465 -0.0077
 23     24     25     26     27     28     29     30     31     32     33
 0.0432 -0.7217 -0.1646 -0.0275  0.0423  0.0535 -0.0360  0.0509 -0.0123  0.1161  0.1158
 34     35     36     37     38     39     40     41     42     43     44
 0.0132  0.0351 -0.5345 -0.0638 -0.0193  0.0146  0.0532  0.0149  0.0937  0.0292  0.0760
 45     46     47     48     49     50     51     52     53     54     55
 0.0409  0.0517  0.0446 -0.3722 -0.0497  0.0023  0.0072  0.0378  0.0288  0.0705  0.0647
 56     57     58     59     60
 0.0590  0.0083  0.0333  0.0459 -0.1327

Order selected 60  sigma^2 estimated as  6.109e-05
```

```
Call:
ar(x = zarobst3, aic = FALSE, order.max = 60, method = "burg")

Coefficients:
 1      2      3      4      5      6      7      8      9     10     11
-0.2611 -0.0167  0.0235  0.0143 -0.0772  0.0073 -0.0293  0.0248  0.0589  0.0198  0.0610
 12     13     14     15     16     17     18     19     20     21     22
-0.9304 -0.2473  0.0056  0.0862  0.0084 -0.0802 -0.0225 -0.0384  0.0562  0.0668  0.0385
 23     24     25     26     27     28     29     30     31     32     33
 0.0737 -0.8288 -0.2181 -0.0058  0.1078  0.0504 -0.0369  0.0867 -0.0066  0.0787  0.1253
 34     35     36     37     38     39     40     41     42     43     44
 0.0699  0.0788 -0.6190 -0.0948 -0.0063  0.0592  0.0477  0.0337  0.1337  0.0356  0.0389
 45     46     47     48     49     50     51     52     53     54     55
 0.0347  0.1028  0.0948 -0.4177 -0.0638  0.0120  0.0364  0.0321  0.0475  0.1059  0.0715
 56     57     58     59     60
 0.0317 -0.0030  0.0650  0.0830 -0.1435

Order selected 60  sigma^2 estimated as  4.981e-05
```

```
Call:
ar(x = zarobst3, aic = TRUE, order.max = 100)

Coefficients:
    1      2      3      4      5      6      7      8      9     10     11
-0.2556 -0.0436 -0.0089  0.0264 -0.0710 -0.0070 -0.0348  0.0417  0.0479 -0.0099  0.0478
    12     13     14     15     16     17     18     19     20     21     22
-0.8540 -0.2100 -0.0259  0.0276  0.0154 -0.0756 -0.0481 -0.0435  0.0814  0.0465 -0.0077
    23     24     25     26     27     28     29     30     31     32     33
 0.0432 -0.7217 -0.1646 -0.0275  0.0423  0.0535 -0.0360  0.0509 -0.0123  0.1161  0.1158
    34     35     36     37     38     39     40     41     42     43     44
 0.0132  0.0351 -0.5345 -0.0638 -0.0193  0.0146  0.0532  0.0149  0.0937  0.0292  0.0760
    45     46     47     48     49     50     51     52     53     54     55
 0.0409  0.0517  0.0446 -0.3722 -0.0497  0.0023  0.0072  0.0378  0.0288  0.0705  0.0647
    56     57     58     59     60
 0.0590  0.0083  0.0333  0.0459 -0.1327

Order selected 60  sigma^2 estimated as  6.109e-05
```

Z powyższych screenów możemy wnioskować, że wartość policzona metodą Yule-Walkera, oraz Burga dla  $p=60$  jest taka samo jak obliczona automatycznie.

## 10. Współczynnik modelu MA

- Dane I

```
147 #wspolczynnik modelu MA----
148 #dane1
149 wspama_domy <- Arima(domys, order = c(0,0,12))
150 summary(wspama_domy)
151
```

```
Series: domys
ARIMA(0,0,12) with non-zero mean

Coefficients:
    ma1    ma2    ma3    ma4    ma5    ma6    ma7    ma8    ma9    ma10    ma11    ma12
 0.5667  0.6394  0.7352  0.6235  0.6364  0.6693  0.6205  0.5756  0.5647  0.4013  0.3489  0.0835
s.e.  0.0490  0.0557  0.0614  0.0671  0.0683  0.0675  0.0633  0.0610  0.0596  0.0626  0.0550  0.0494

    mean
9966.6317
s.e.  539.1009

sigma^2 = 2271059:  log likelihood = -3594.6
AIC=7217.19  AICc=7218.25  BIC=7273.49

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -17.57573 1483.037 1110.009 -4.897129 13.37214 0.5562116 0.004823892
```

- Dane II

```
152 #dane2
153 wspama_zarobki <- Arima(zarobkis, order =c(0,0,12))
154 summary(wspama_zarobki)
155
```

```

Series: zarobkis
ARIMA(0,0,12) with non-zero mean

Coefficients:
      ma1      ma2      ma3      ma4      ma5      ma6      ma7      ma8      ma9      ma10     ma11     ma12
s.e.  0.0370  0.0739  0.1174  0.1597  0.1950  0.2157  0.2184  0.1991  0.1603  0.1127  0.0645  0.0325

      mean
s.e.  517.9963
      17.0692

sigma^2 = 75.8:  log likelihood = -2340.27
AIC=4708.54  AICc=4709.2  BIC=4771.28

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.1102859 8.619093 6.147855 -0.8357828 1.734022 0.358764 0.1176729

```

11. Wyznaczanie optymalnych modeli z użyciem `auto.arima()`

```

(ar1 <- auto.arima(domyst3, ic = "aicc"))

```

```

Series: domyst3
ARIMA(2,0,0)(2,0,0)[12] with non-zero mean

Coefficients:
      ar1      ar2      sar1      sar2      mean
s.e.  -0.6957 -0.4228 -0.7278 -0.4305  6e-04
      0.0465  0.0455  0.0468  0.0461  2e-03

sigma^2 = 0.03068:  log likelihood = 126.84
AIC=-241.68  AICc=-241.46  BIC=-217.74
>

```

```

155 (ar1 <- auto.arima(domyst3, ic = "aicc"))
160 (ar2 <- auto.arima(domyst3, ic = "aic"))

```

```

> (ar2 <- auto.arima(domyst3, ic = "aic"))
Series: domyst3
ARIMA(2,0,0)(2,0,0)[12] with non-zero mean

Coefficients:
      ar1      ar2      sar1      sar2      mean
s.e.  -0.6957 -0.4228 -0.7278 -0.4305  6e-04
      0.0465  0.0455  0.0468  0.0461  2e-03

sigma^2 = 0.03068:  log likelihood = 126.84
AIC=-241.68  AICc=-241.46  BIC=-217.74

```



```
(ar3 <- auto.arima(domyst3, ic = "bic"))
```

```
> (ar3 <- auto.arima(domyst3, ic = "bic"))
Series: domyst3
ARIMA(3,0,0)(2,0,0)[12] with zero mean

Coefficients:
          ar1          ar2          ar3          sar1          sar2
      -0.7151  -0.4592  -0.0544  -0.7105  -0.4234
s.e.    0.0502   0.0577   0.0532   0.0498   0.0466

sigma^2 = 0.03064:  log likelihood = 127.32
AIC=-242.63   AICc=-242.42   BIC=-218.7
```

```
163 (ar4 <- auto.arima(zarobst3 , ic = "aicc"))
164 (ar5 <- auto.arima(zarobst3 , ic = "aic"))
165 (ar6 <- auto.arima(zarobst3 , ic = "bic"))
166
```

```
> (ar4 <- auto.arima(zarobst3 , ic = "aicc"))
Series: zarobst3
ARIMA(1,0,0)(1,0,0)[12] with non-zero mean

Coefficients:
          ar1          sar1      mean
      -0.2580  -0.4994   0e+00
s.e.    0.0383   0.0344   2e-04

sigma^2 = 7.863e-05:  log likelihood = 2115.86
AIC=-4223.72   AICc=-4223.66   BIC=-4205.88
```

```
> (ar5 <- auto.arima(zarobst3 , ic = "aic"))
Series: zarobst3
ARIMA(1,0,0)(1,0,0)[12] with non-zero mean

Coefficients:
          ar1          sar1      mean
      -0.2580  -0.4994   0e+00
s.e.    0.0383   0.0344   2e-04

sigma^2 = 7.863e-05:  log likelihood = 2115.86
AIC=-4223.72   AICc=-4223.66   BIC=-4205.88
>
```

```

> (ar6 <- auto.arima(zarobst3 , ic = "bic"))
Series: zarobst3
ARIMA(0,0,1)(1,0,0)[12] with zero mean

Coefficients:
          ma1          sar1
      -0.2593   -0.4984
s.e.      0.0375    0.0344

sigma^2 = 7.851e-05: log likelihood = 2115.88
AIC=-4225.76   AICc=-4225.73   BIC=-4212.38
> |

```

## 12. Prognozowanie z wykorzystaniem metod naiwnych


Zrobiłem prognozowanie 4 metodami: opartą na średniej, naiwną, s-naiwną, oraz naiwną z uwzględnieniem dryfu

```


167
168 #prognozowanie z wykorzystaniem metod naiwnych----
169 #Na podstawie sredniej dane 1
170 domysmeanf <- meanf(domys, 12)
171 plot(domysmeanf)
172 #metoda naive dane 1
173 domysnaive <- naive(domys, 12)
174 plot(domysnaive)
175 #metoda snaive dane 1
176 domyssnaive <- snaive(domys,12)
177 plot(domyssnaive)
178 #z uwzgl?dnieniem dryfu dane 2
179 domysdryf <- rwf(domys, 12, drift = TRUE)
180 plot(domysdryf)

```


Forecasts from Mean




Forecasts from Naive method



Forecasts from Seasonal naive method

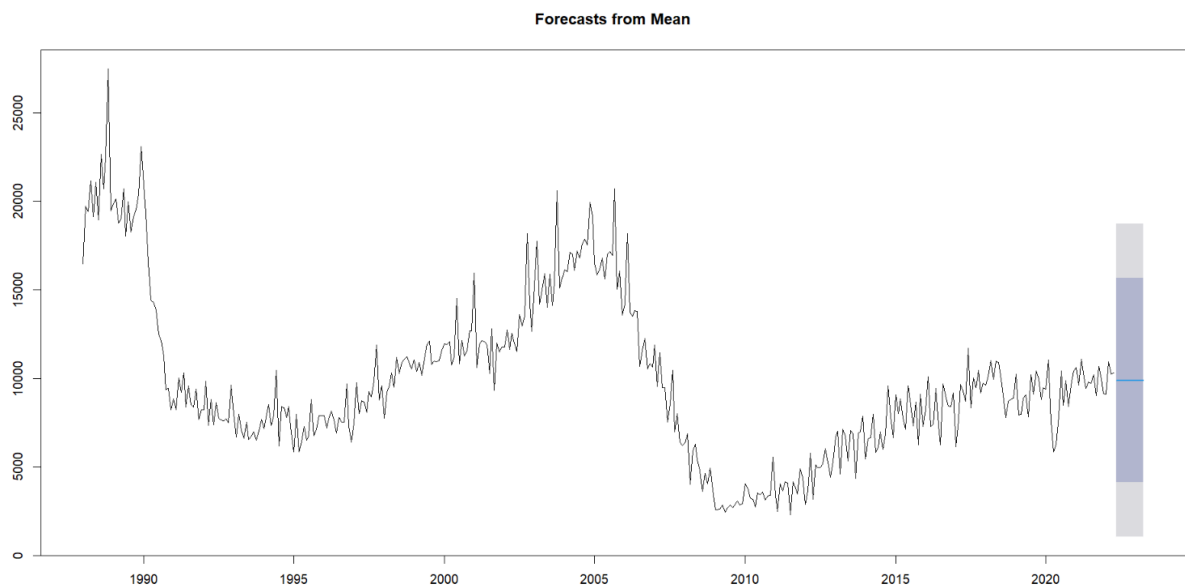


Forecasts from Random walk with drift




- Dane II


```
183 #Na podstawie sredniej dane 2
184 zarobkimeanf <- meanf(zarobkis, 12)
185 plot(domysmeanf)
186 #metoda naive dane 2
187 zarobkinaive <- naive(zarobkis, 12)
188 plot(domysnaive)
189 #metoda snaive dane 2
190 zarobkisnaive <- snaive(zarobkis,12)
191 plot(domyssnaive)
192 #z uzwgl?dnieniem dryfu dane 2
193 zarobkidryf <- rwf(zarobkis, 12, drift = TRUE)
194 plot(domysdryf)
195
```




Forecasts from Naive method



Forecasts from Seasonal naive method





## 12.1 Wybór najlepszej metody

```

196 #wybor najlepszej metody----
197 #dane 1
198 (accuracy(domysmeanf))|
199 (accuracy(domysnaive))
200 (accuracy(domyssnaive))
201 (accuracy(domysdryf))
202
203 #dane 2
204 (accuracy(zarobkimeanf))
205 (accuracy(zarobkinaive))
206 (accuracy(zarobkisnaive))
207 (accuracy(zarobkidryf))
208

```

- Dane I

```

> (accuracy(domysmeanf))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 7.342967e-15 4481.865 3403.597 -26.06977 46.72169 1.705499 0.9319739
> (accuracy(domysnaive))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -14.92021 1622.867 1200.531 -1.750579 13.66605 0.6015709 -0.4605427
> (accuracy(domyssnaive))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -325.0626 2767.563 1995.66 -7.092817 24.53309 1 0.6410127
> (accuracy(domysdryf))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -1.173244e-13 1622.798 1201.231 -1.560067 13.65994 0.6019219 -0.4605427
>

```

Najwięcej wartości, które są najmniejsze przypadają dla metody z naiwnej z uwzględnieniem dryfu. Oznacza to, że możemy uznać tą metodę za najlepszą.

- Dane II

```
> #dane 2
> (accuracy(zarobkimeanf))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -1.651078e-14 252.569 215.9852 -42.89621 69.79133 12.60402 0.994739
> (accuracy(zarobkinaive))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.405675 4.348168 2.624969 0.3348529 0.5647019 0.1531826 -0.1975384
> (accuracy(zarobkisnaive))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 16.6593 20.04475 17.13621 3.905685 3.967628 1 0.8566073
> (accuracy(zarobkidryf))
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.789353e-14 4.114686 2.25892 -0.05231636 0.4812015 0.1318214 -0.1975384
> |
```

Najwięcej wartości, które są najmniejsze przypadają dla metody z naiwnej z uwzględnieniem dryfu. Oznacza to, że możemy uznać tą metodę za najlepszą.